

Rozdział 1

Wstęp

1.1 Cassandra

Apache Cassandra to darmowa, rozproszona baza danych przeznaczona do zarządzania dużymi ilościami ustrukturyzowanych danych. Projekt powstał, aby umożliwić realizację funkcjonalności przeszukiwania skrzynki odbiorczej użytkownika na portalu Facebook¹. Funkcjonalność ta nie była możliwa do zrealizowania w oparciu o tradycyjny, relacyjny model bazy danych. W 2008 Facebook udostępnił kod źródłowy Cassandra, która następnie (w 2010 roku) została wcielona do projektów pod opieką fundacji Apache². [1]

Apache Cassandra jest częścią ruchu NoSQL³. Chociaż brakuje oficjalnej, ustanowionej odgórnie definicji pojęcia NoSQL możemy wyróżnić zestaw cech wspólnych baz danych, które powszechnie zaliczane są do tej grupy:

- Wewnętrzna reprezentacja danych w bazach NoSQL nie opiera się na tabelach i relacjach.
- Brak pełnej implementacji języka SQL. Chociaż niektóre bazy NoSQL wykorzystują język zapytań o składni podobnej do SQL, żadna z nich nie implementuje jej w pełni.
- Bazy NoSQL posiadają elastyczny model danych. Nie wykorzystują sztywnego, narzuconego z góry schematu.
- Model danych w bazach NoSQL jest zazwyczaj ukierunkowany na łatwe klastrowanie, chociaż istnieją wyjątki od tej reguły (na przykład Neo4j⁴).
- Bazy NoSQL są przystosowane do wymagań nowoczesnych portali internetowych, które muszą obsługiwać ogromne zbiory danych z szybkim czasem dostępu. [4]

¹Popularny portal społecznościowy dostępny pod adresem <http://fb.com>.

²Fundacja wspierająca powstawanie oprogramowania o otwartym źródle.

³NoSQL - *Not only SQL* (ang. nie tylko SQL).

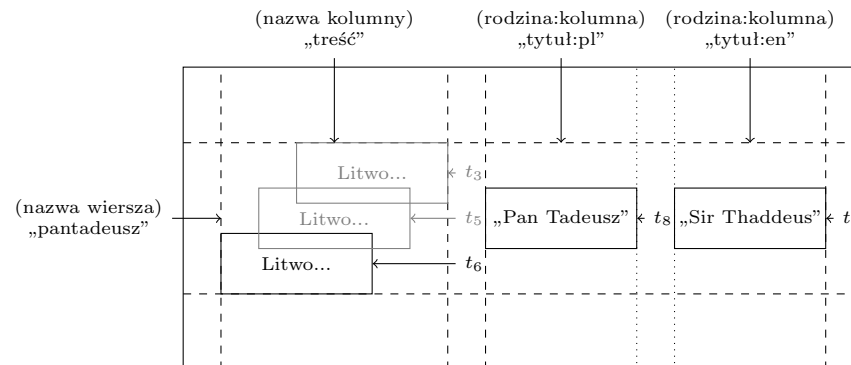
⁴Neo4j - baza danych oparta wewnętrznie o grafy.

Konsekwencją ostatniej cechy jest odejście od idei właściwości ACID. Zestaw cech ACID⁵ to minimalny zbiór cech, które gwarantują realizację transakcyjności w bazie danych. [3] Klastrowanie sprawia, że nie da się zachować spójności danych na wszystkich węzłach, stąd wymagane są inne mechanizmy zachowania poprawności danych.

1.2 Historia Cassandra

Apache Cassandra powstała z połączenia rozwiązań wykorzystywanych w dwóch mechanizmach bazodanowych: Google Bigtable oraz Amazon Dynamo. Google Bigtable to rozproszony system bazodanowy do przechowywania ustrukturyzowanych danych. Został stworzony z myślą o skalowaniu dla ogromnych ilości danych. Wykorzystywany jest między innymi w takich produktach jak Google Analytics, Google Finance, Google Earth oraz mechanizmach takich jak spersonalizowane wyszukiwanie w przeglądarce Google.

Model danych w Google Bigtable jest opisany trójwymiarową strukturą mapy. Mapa ta jest identyfikowana unikalnymi kluczami, które reprezentują klucz wiersza, nazwę (klucz) kolumny oraz znacznik czasu. Wszystkie wiersze są uporządkowane w rosnącym porządku leksykograficznym względem klucza. W każdej komórce mapy przechowywane są wartości w postaci łańcucha znaków, co implikuje konieczność serializacji i deserializacji wartości w aplikacjach klienckich. Dodatkowo, nazwy kolumn mogą być grupowane w rodziny. Nazwa każdej kolumny w rodzinie jest poprzedzona klasyfikatorem, który identyfikuje tę rodzinę (w formacie *rodzina:nazwa_kolumny*). [2] Schematyczny rysunek przykładowej struktury danych przedstawiono na rysunku 1.1.



Rysunek 1.1: Schematyczne przedstawienie modelu danych dla Google Bigtable na przykładzie fragmentu danych książek.

⁵ACID - skrót od *Atomicity, Consistency, Isolation, Durability* (ang. atomowość, jednolitość, izolacja, trwałość)

1.3 Architektura

Placeholder.

Bibliography

- [1] DataStax. *Introduction to Apache Cassandra*. Apr. 14, 2014. URL: <http://www.datastax.com/docs/0.8/introduction/index>.
- [2] Sanjay Ghemawat Wilson C. Hsieh Deborah A. Wallach Mike Burrows Tushar Chandra Andrew Fikes Robert E. Gruber Fay Chang Jeffrey Dean, ed. *Bigtable: A Distributed Storage System for Structured Data*. Google, Inc., 2006.
- [3] Jim Gray, ed. *The Transaction Concept: Virtues and Limitations*. Proceedings of Seventh International Conference on Very Large Databases. 19333 Vallco Parkway, Cupertino CA 95014: Tandem Computers Incorporated, 1981.
- [4] Martin Fowler Pramod J. Sadalage. *NoSQL Distilled*. Pearson Education, 2013. ISBN: 978-0-321-82662-6.